품절과 과잉 사이의 최적점 찾기:

1,000만 건 거래 데이터 기반 수요 예측과 재고 운영 개선

전 유 진

프로젝트 자세히 보기

비즈니스 임팩트 및 주요 성과

10M+

처리된 소매 거래 데이터 레코드 수

-3,020

전체 RMSE 오차 감소량

(Baseline 26,460
→ Feature Model 23,440)

~1,020 Units

월평균 수요 오차 감소량

약 508만 원

월평균 비용 절감액 (예상)
(단위가격: 4,980원 기준)

비즈니스 가치 요약:

- 과잉 재고(Overstock) 리스크 감소
- 품절(Stockout) 확률 최소화
- 안정적이고 예측 가능한 재고 기획(Inventory Planning) 지원

문제 정의: 재고 관리의 딜레마

[리스크 1] 과잉 재고 (Overstock)

➜ 보관 및 유지 비용 증가

[리스크 2] 품절 (Stockouts)

➜ 매출 기회 상실 및 고객 경험 하락

핵심 과제: 단순히 과거 7일 전 데이터를 그대로 사용하는 '계절성 베이스라인(Seasonal Naive)'의 한계를 극복하고, 예측 정확도를 실질적으로 높일 수 있는 머신러닝 모델의 필요성 대두.

데이터 개요 및 엔지니어링 과제

데이터 규모

10개의 CSV 파일로 분할된
160MB(압축 기준) 이상의
1,000만 건(10M+) 대규모 데이터

메모리 한계

한 번에 RAM에 로드할 수 없는
대용량 스케일

데이터 품질

결측치(예: 누락된 상품명) 및 불일치하는
문자열 포맷

제로 세일즈(Zero-sales)

퍼센트 기반 오차 지표(MAPE 등)를
왜곡하는 판매량 0 구간의 존재

메모리 효율을 극대화한 Chunk-based 전처리 파이프라인

1. 압축 해제 및 탐색
(CSV 파일 로드)

→

2. Chunk 읽기
(한 번에 50만 건씩 분할 로드하여 메모리 초과 방지)

→

3. 정제 및 정규화
(문자열 공백 제거 및 결측된 상품명을 카테고리명으로 대체하여 손실 최소화)

→

4. 병합 및 저장
(처리된 Chunk를 효율적인 Parquet 포맷으로 저장)

시간적 수요 패턴 탐색 (Temporal Demand Patterns)

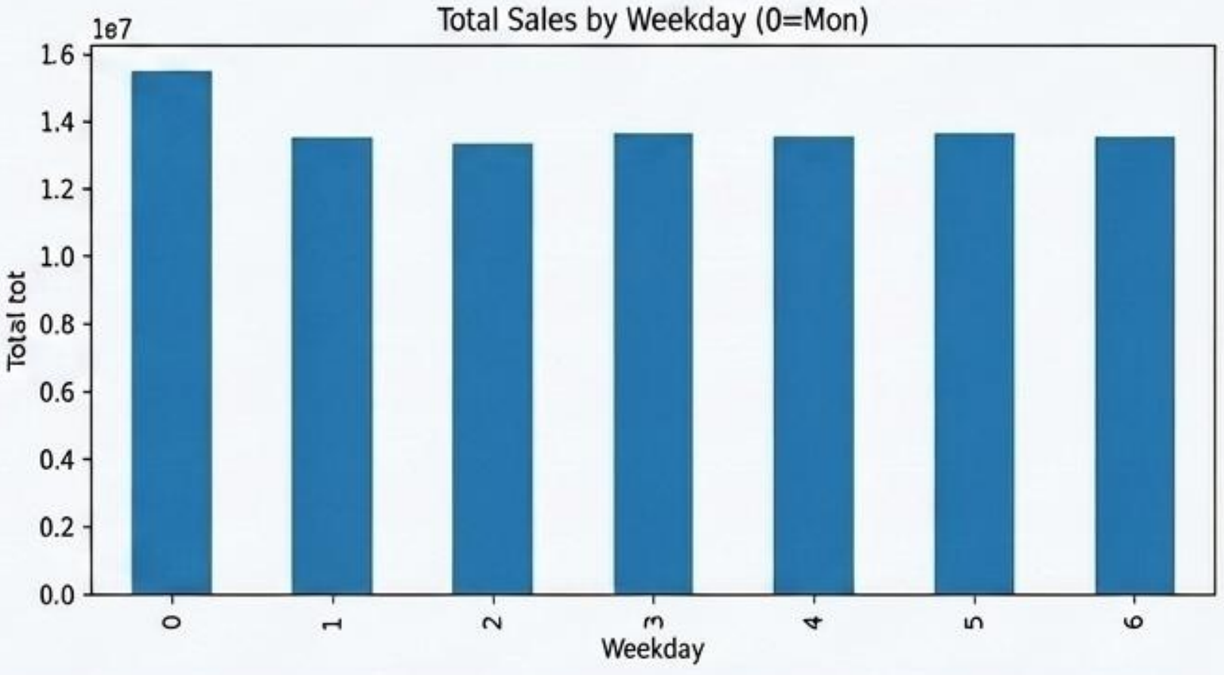

핵심 인사이트: 특정 시간대 및 요일별에 따른 명확하고 규칙적인 수요 사이클 존재.
ANOVA 통계 테스트 결과, 시간대별 및 요일별 매출 차이는 모두 통계적으로 매우 유의미함(p-value < 0.001).

➡ 이는 예측 모델에서 'hour', 'weekday' 등의 시계열 피처(Feature)가 매우 강력한 신호로 작용할 것임을 시사함.

카테고리별 수요 규모와 변동성의 상관관계

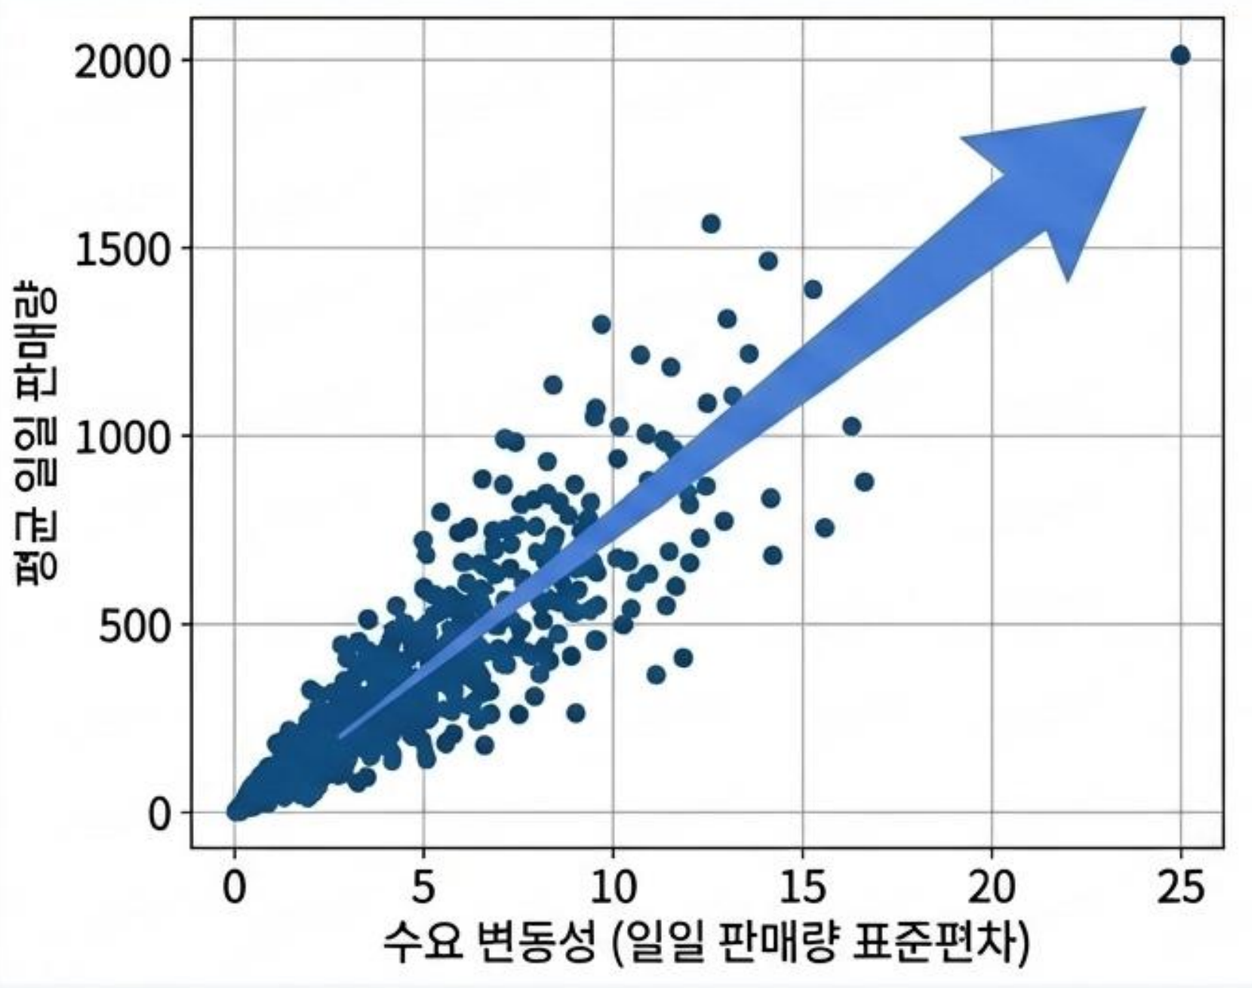

핵심 인사이트:

▶ 평균 판매량이 높은 카테고리일수록 수요의 변동성(표준 편차) 또한 높게 나타난다.

▶ **통계적 유의성:** Pearson 상관계수는 약 0.91로, 매우 강한 양의 상관관계를 통계적으로 확인.

비즈니스 의미:

▶ 거래 규모가 큰 고수요 카테고리일수록 수요의 등락폭이 커서 예측 난이도가 근본적으로 높음.

피처 엔지니어링 및 모델링 전략

Baseline Model

과거 7일 전 동일 시점 수요를 그대로 사용하는 계절성 모델

방식: Prediction(t) = demand(t-7)

Feature Model

HistGradientBoostingRegressor 기반의 고도화된 머신러닝 모델

핵심 활용 피처 (Engineered Features):

- 수요 지속성 반영: lag_1, lag_7, lag_14, lag_28
- 단기 수요 변동 반영: rolling mean(7), rolling std(7)
- 주간/계절성 반영: weekday, month

예측 성과 시각화: Predicted vs Actual

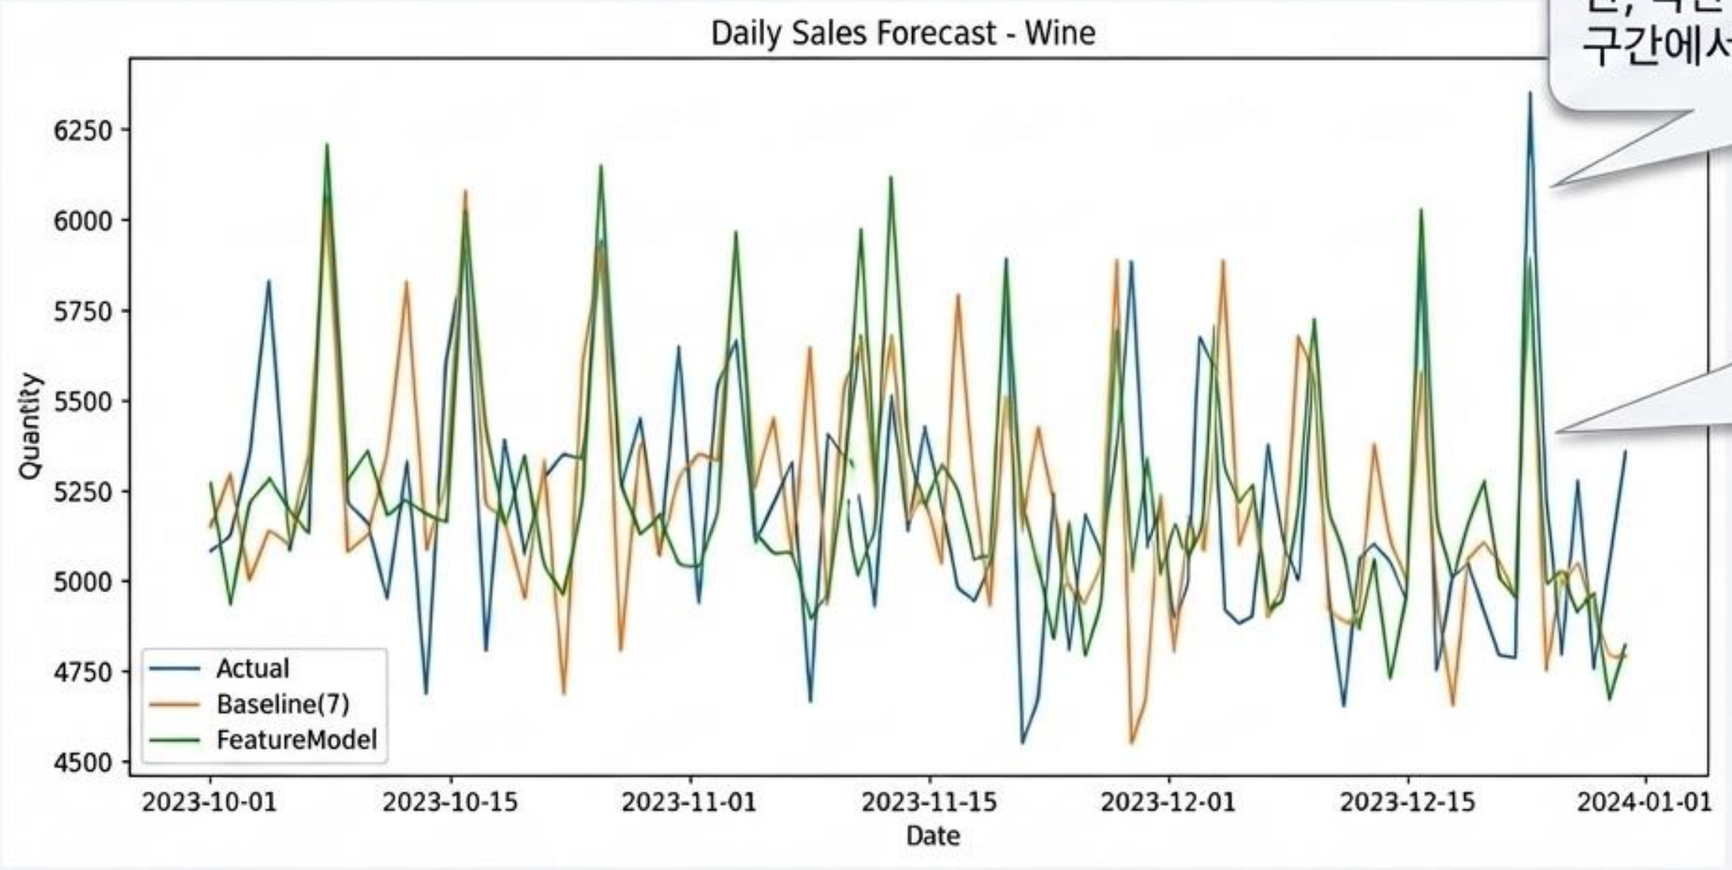

단, 극단적인 수요 **급증(Spikes)** 구간에서는 여전히 예측의 한계가 존재함.

Feature Model(초록선)이 Baseline(주황선) 대비 **실제 수요의 전반적인 흐름과 수준을 훨씬 더 정확하게 추적**함.

요일별 오차 분석 (Performance Tracking by Weekday)

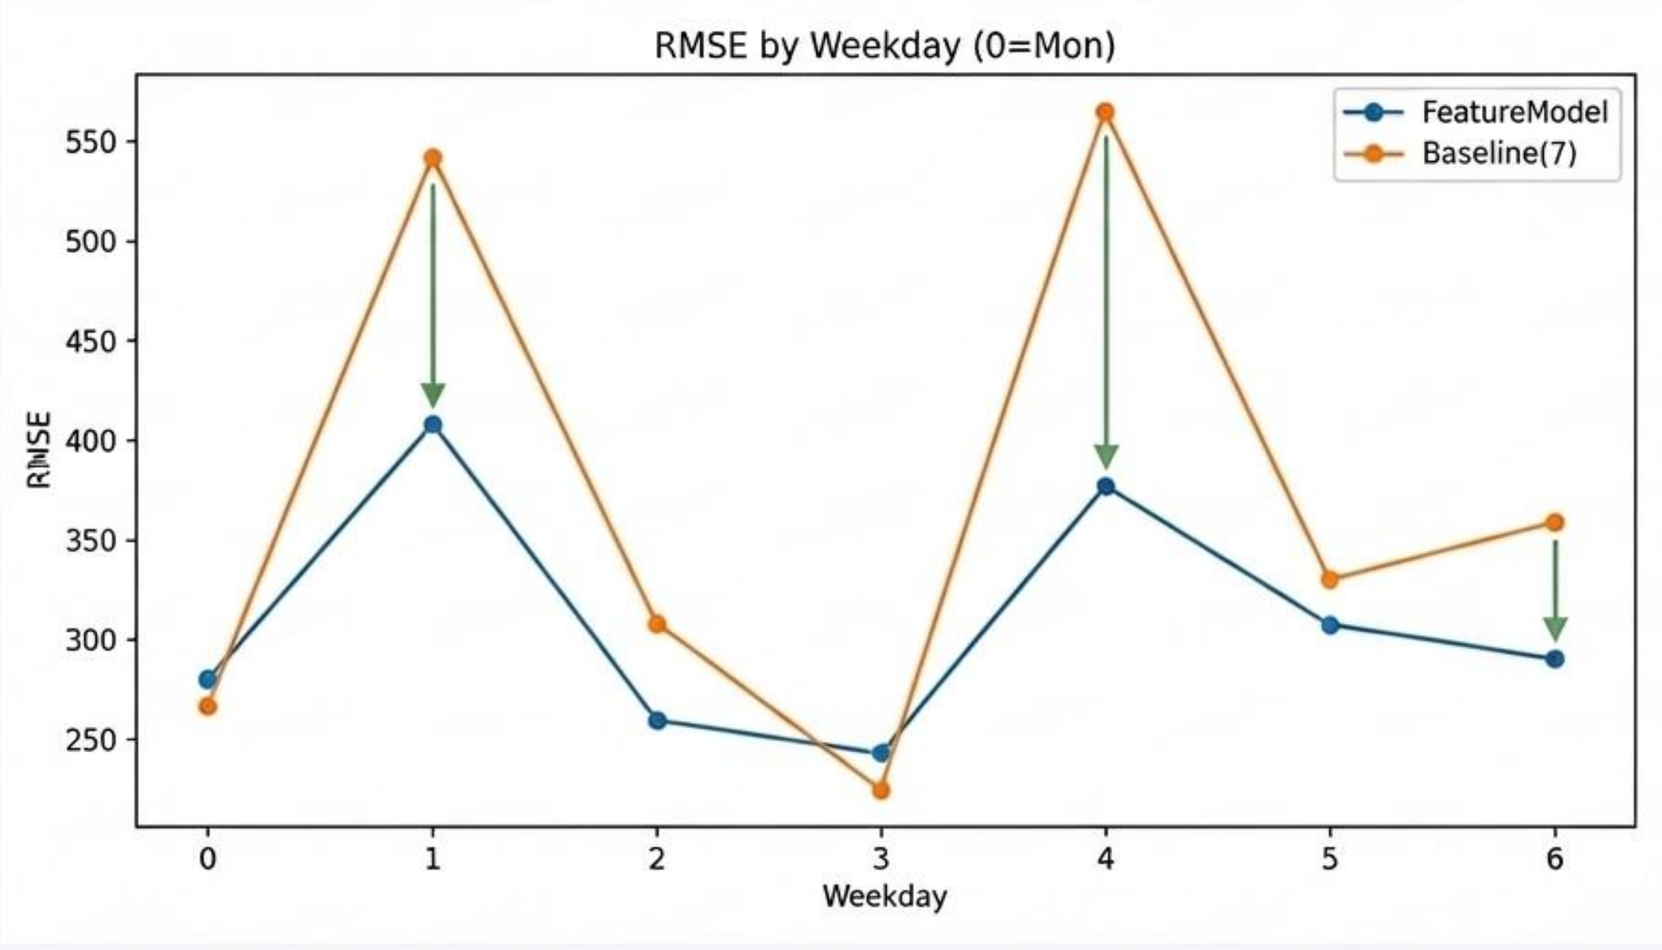

핵심 인사이트:

- Feature Model이 Baseline 대비 모든 요일에서 RMSE를 안정적으로 낮춤.
- 특히 특정 요일의 급격한 수요 변동에 대해 ML 모델이 훨씬 더 견고함**(Robust)**을 시각적으로 증명.

심층 분석: 수요 구간별 예측 오차 (Forecast Error by Demand Segment)

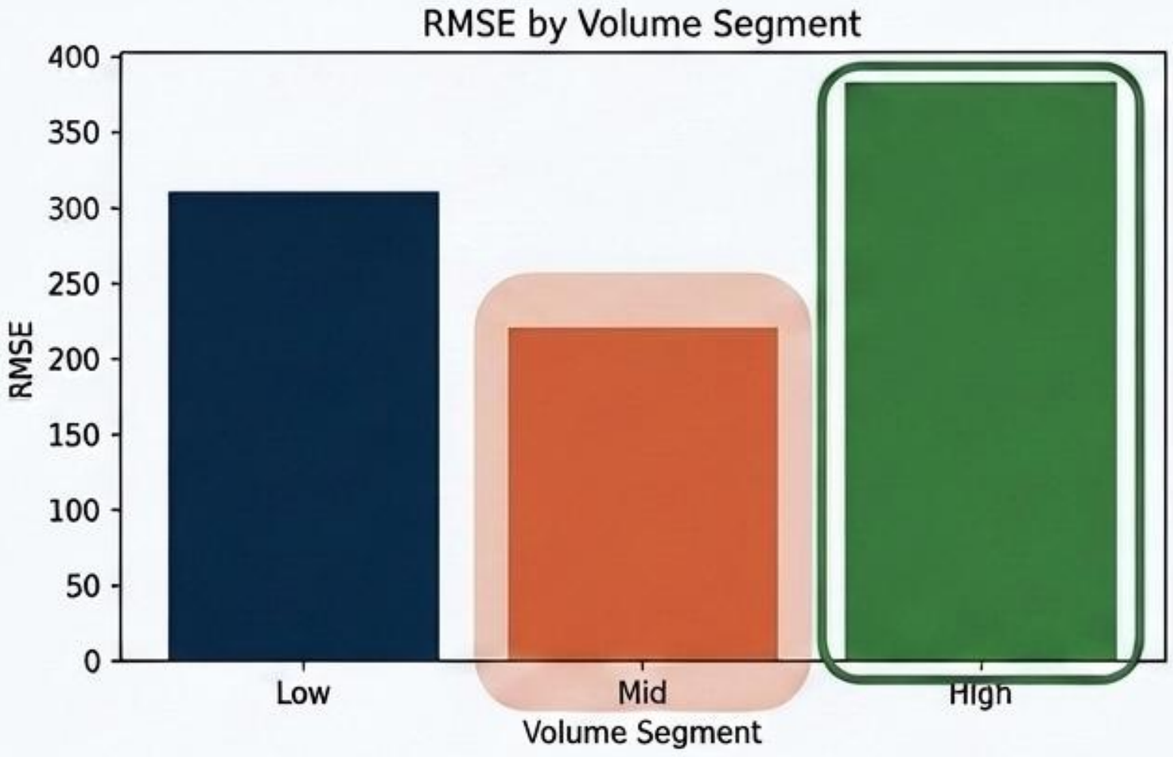

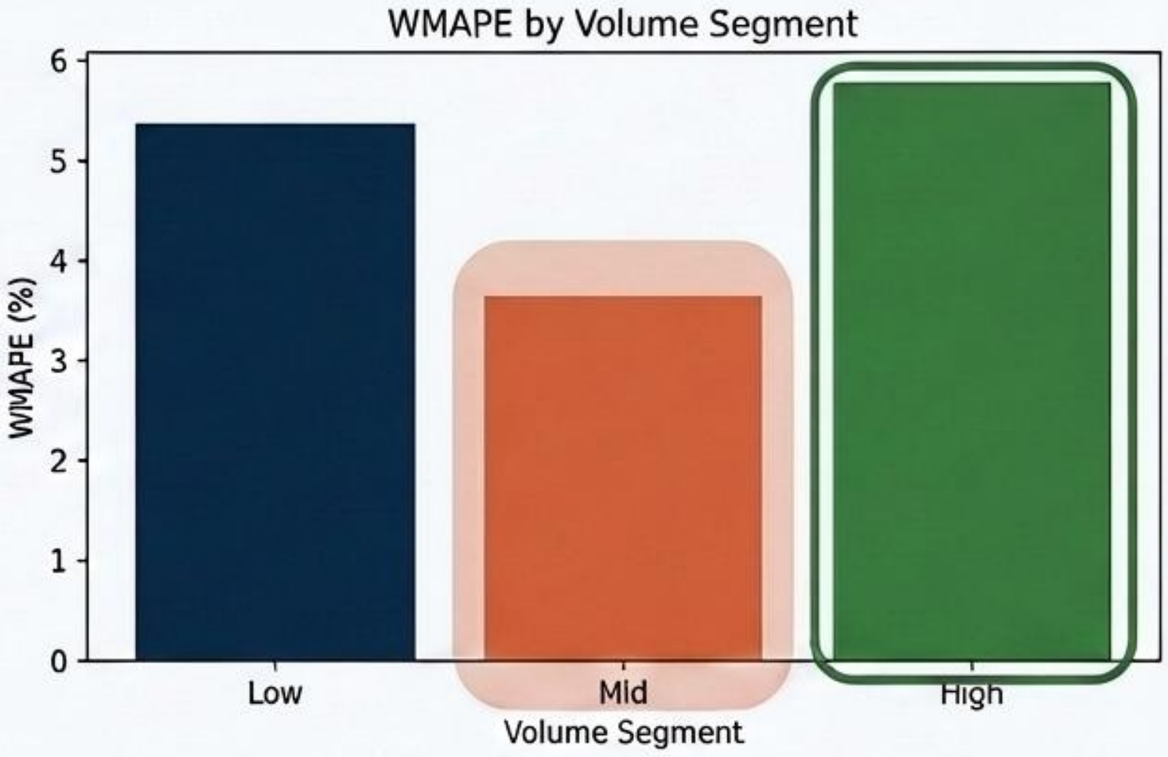

핵심 인사이트 (Finding):

- Mid-demand (중간 수요): WMAPE가 가장 낮아 가장 안정적이고 예측하기 쉬운 구간. ⬇️
- High-demand (고수요): 절대적인 RMSE가 가장 높게 나타나는 예측 최고 난이도 구간. ⬆️

한계점 진단: 수요 급증(Demand Spikes)의 어려움

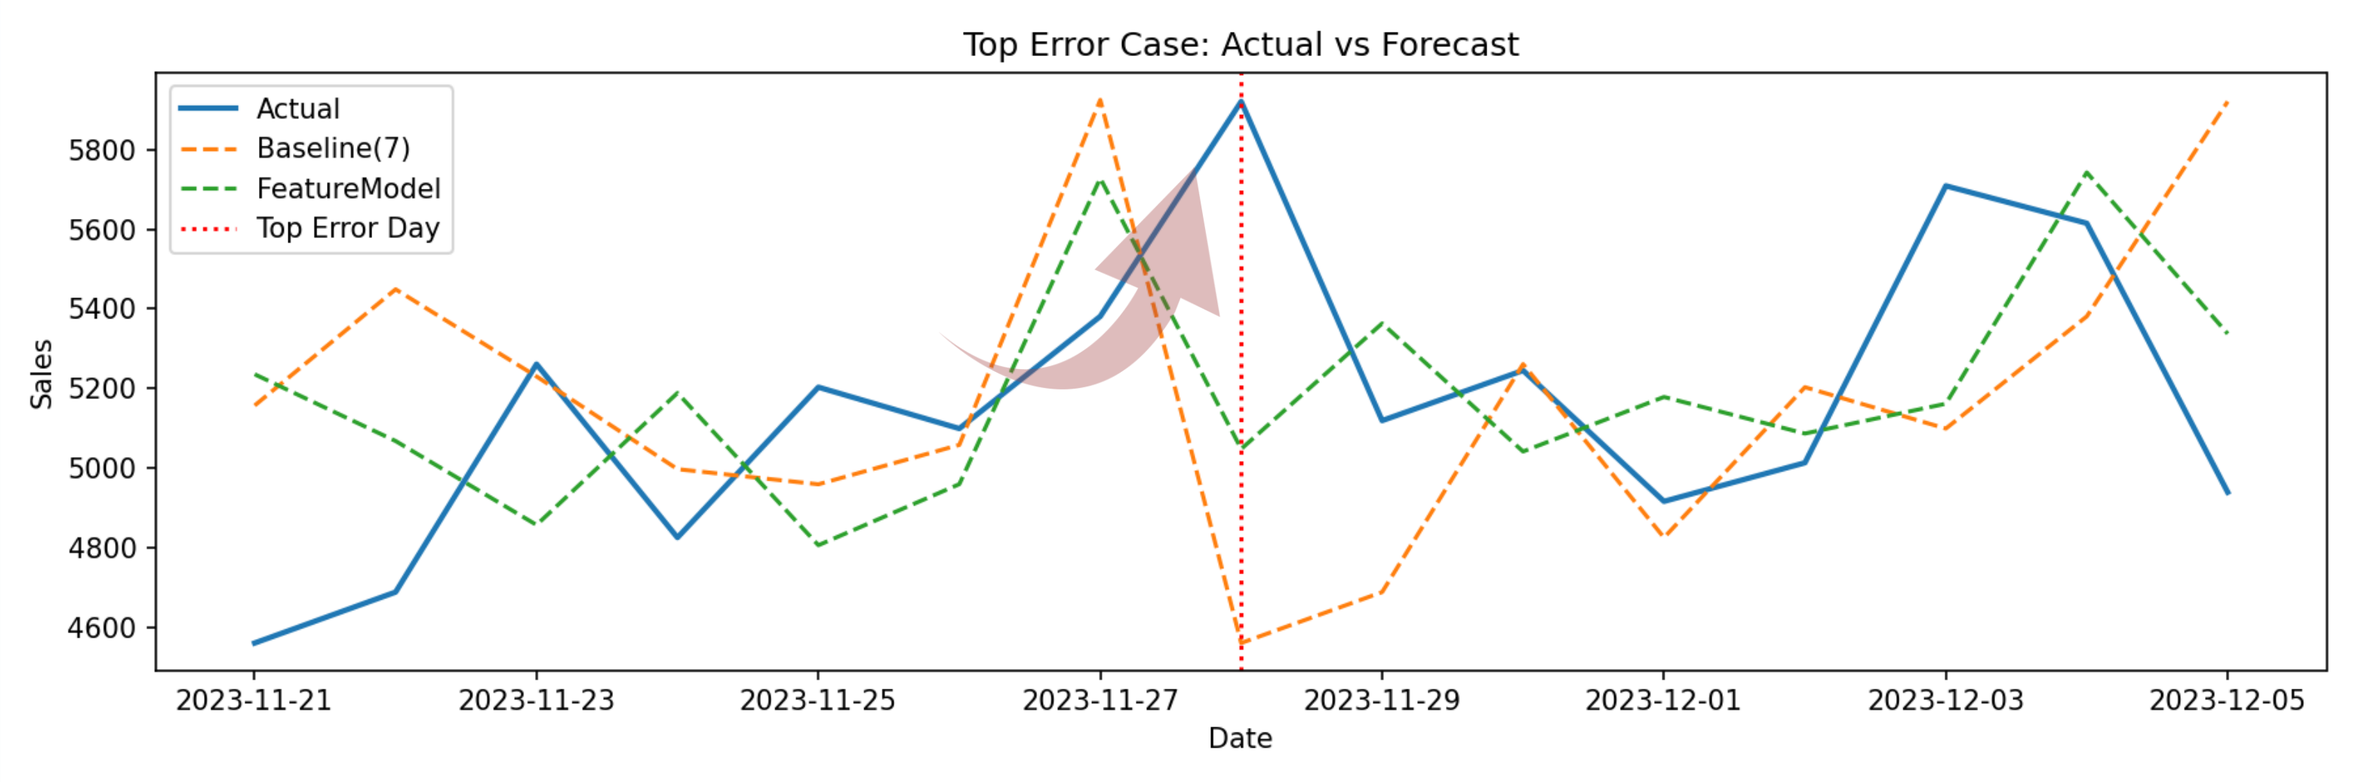

분석 요약:

- **예측 오차**는 단순히 수요의 크기에 비례하지 않으며, **수요 구간**에 따라 크게 좌우됨.
- 과거의 거래 데이터(Lag, Rolling stats)만으로는 돌발적인 수요 급증(Spikes)을 예측하는 데 근본적인 한계 존재.

결론:

- 예측 실패의 가장 큰 원인은 이러한 **돌연한 수요의 스파이크 현상**에 있었음.

핵심 분석 결과 및 프로젝트 성과

- ML 기반 수요 예측 모델 → **RMSE 3,020 감소**
- **예측 오차**는 랜덤이 아니라, **특정 수요 구간**과 **수요 급등** 이벤트에 집중
- **WMAPE** 평가 적용 → **매출 영향이 큰 수요 구간의 오차 우선 관리**
- **1,000만 건 데이터 처리** 파이프라인 구축 및 **시계열 수요 예측 모델링** 수행

향후 운영 전략

Mid-demand 상품

예측 신뢰도가 매우 높으므로, 보관 비용을 줄이는 타이트한 **최적화/린(Lean) 재고 운영 추천**.

High-demand 상품

돌발적인 수요 급증에 따른 오차가 크므로, 품절 방지를 위한 **충분한 버퍼(Buffer) 재고 확보 필수**.

수요 급증 이벤트

외생 변수 추가 도입 통해 수요 급증 구간의 예측 불확실성 감소.

- 프로모션 일정 (할인 행사 / 기획전)
- 마케팅 캠페인 (광고 유입 이벤트)
- 재고 가용성 (품절 / 진열 상태)

프로젝트 자세히 보기